

• • • • • • •

DATA WAREHOUSE PARA UTM

PROYECTO SEGUNDO PARCIAL

EXTRACCIÓN BD

INTEGRANTES:

Brayan David Casas Morales	22607
Devany Guadalupe Zapata Chávez	22634
Edgar Alexis Quintero Zavaleta	22630
Ángel Antonio Loza Flores	22624

MARTES 7 DE JULIO DE 2026

• • • • •
• • • • •
• • • • •
• • • • •

Índice

- [1. Introducción](#)
- [2. Objetivos](#)
- [3. Caso de estudio](#)
- [4. Tipos y fuentes de datos](#)
- [5. Fase 1: Creación del conjunto de datos](#)
- [6. Fase 2: Identificación de tipos y fuentes](#)
- [7. Fase 3: Extracción de datos](#)
- [8. Fase 4: Transformación y limpieza de datos](#)
- [9. Fase 5: Diseño del Data Warehouse](#)
- [10. Fase 6: Configuración del Data Warehouse](#)
- [11. Fase 7: Carga de datos](#)
- [12. Fase 8: Repositorio del proyecto](#)
- [13. Evidencias del proceso ETL](#)
- [14. Resultados esperados y consultas de análisis](#)
- [15. Conclusiones](#)
- [16. Anexos](#)

1. Introducción

Actualmente, las instituciones educativas generan y almacenan grandes cantidades de información académica en diferentes sistemas, como plataformas escolares, archivos de Excel, sistemas de asistencia y plataformas virtuales de aprendizaje. Sin embargo, cuando estos datos se encuentran separados, incompletos o con errores, resulta complicado analizarlos de manera eficiente para tomar decisiones académicas.

Por esta razón, es importante integrar y preparar los datos mediante un proceso ETL, el cual permite extraer la información desde sus fuentes originales, transformarla mediante técnicas de limpieza y cargarla en una base de datos organizada. Este proceso ayuda a corregir errores, eliminar duplicados, completar datos faltantes y estructurar la información para su análisis posterior.

En este proyecto se desarrolla un Data Warehouse enfocado en el análisis del rendimiento académico de estudiantes universitarios. A través de un modelo estrella y la carga de datos en MySQL, se busca organizar la información de manera clara para consultar aspectos como el promedio por carrera, alumnos en riesgo académico, relación entre asistencia y rendimiento, y materias con menor desempeño. De esta forma, el Data Warehouse se convierte en una herramienta útil para apoyar la toma de decisiones dentro del ámbito académico.

[↑ Regresar al índice](#)

2. Objetivos

2.1 Objetivo general

Desarrollar un Data Warehouse para una universidad utilizando un proceso ETL, aplicando limpieza de datos y generando un conjunto preprocesado listo para minería de datos y Machine Learning.

2.2 Objetivos específicos

- Crear un conjunto de datos académico con errores intencionales.
- Aplicar limpieza y transformación de datos mediante Power Query.
- Diseñar un esquema estrella para organizar la información académica.
- Crear la base de datos y las tablas del Data Warehouse en MySQL.
- Documentar el proceso con capturas y subir los archivos al repositorio.

[↑ Regresar al índice](#)

3. Caso de estudio

La Universidad Tecnológica Montemorelos cuenta con información académica de sus estudiantes distribuida en diferentes fuentes de datos. Entre estas fuentes se encuentran el Sistema Escolar, la plataforma Moodle, la Biblioteca y archivos de Excel de Servicios Escolares. Cada sistema almacena información diferente y con formatos distintos, lo que dificulta obtener una visión completa del rendimiento académico de los alumnos.

El principal problema es que la información no se encuentra integrada en una sola base de datos. Por ejemplo, los datos generales del alumno pueden estar en el Sistema Escolar, los accesos a la plataforma educativa en Moodle, la actividad de consulta o préstamo de materiales en Biblioteca y las calificaciones en archivos de Excel. Esta separación complica el análisis académico y hace más difícil detectar alumnos en riesgo, carreras con mayor reprobación o posibles relaciones entre asistencia y promedio.

Por esta razón, se propone diseñar e implementar un Data Warehouse académico, utilizando un proceso ETL para extraer, limpiar, transformar y cargar los datos en una estructura organizada. Con esto, la universidad podrá consultar la información de manera más clara y tomar decisiones basadas en datos, como identificar áreas de bajo rendimiento, alumnos que necesitan apoyo académico y carreras donde se requiere mayor seguimiento.

Pregunta de análisis	Dato necesario
¿Qué carrera tiene mayor índice de reprobación?	Carrera, promedio, nivel académico
¿Qué alumnos presentan riesgo académico?	Matrícula, nombre del alumno, promedio, asistencia, accesos Moodle, nivel académico
¿Existe relación entre asistencia y promedio?	Asistencia, promedio
¿Qué materias tienen menor rendimiento?	Materia, promedio, nivel académico
¿Qué carrera presenta mejor rendimiento general?	Carrera, promedio
¿Qué alumnos tienen baja asistencia y bajo promedio?	Alumno, asistencia, promedio, nivel académico

[↑ Regresar al índice](#)

4. Tipos y fuentes de datos

En esta fase se identificaron los tipos y fuentes de datos utilizados en el conjunto de información de los estudiantes. La base de datos contiene campos relacionados con la identificación del alumno, su información académica y su actividad dentro de la plataforma Moodle.

Los datos como matrícula, nombre, carrera, edad y sexo provienen principalmente del Sistema Escolar, ya que corresponden a información general del estudiante. El promedio académico se obtiene del archivo de Excel de Servicios Escolares, mientras que los accesos a Moodle provienen de la plataforma educativa. La asistencia puede obtenerse del sistema de control escolar o de registros internos de clase.

Esta clasificación permite comprender el origen de la información antes de iniciar el proceso de extracción, transformación y carga, facilitando la integración de los datos dentro del Data Warehouse.

Campo	Tipo de dato	Fuente	Observaciones
Matrícula	Cualitativo Identificador	Sistema Escolar	Valor único por alumno
Nombre	Cualitativo	Sistema Escolar	Nombre completo
Carrera	Cualitativo Nominal	Sistema Escolar	Programa académico
Edad	Numérico entero	Sistema Escolar	Validar rangos lógicos
Sexo	Binario/Categorico	Sistema Escolar	M/F u otro criterio definido
Promedio	Cuantitativo continuo	Excel de Servicios Escolares	Rango sugerido: 0 a 100
Asistencia	Cuantitativo continuo	Sistema académico	Porcentaje de 0 a 100
Accesos Moodle	Numérico entero	Plataforma Moodle	Cantidad de accesos

[↑ Regresar al índice](#)

5. Fase 1: Creación del conjunto de datos

Para iniciar el proyecto se creó un archivo llamado alumnos.xlsx utilizando Microsoft Excel. Este archivo contiene una base de datos simulada con 106 registros de estudiantes, tomando como referencia los campos sugeridos para el caso de estudio: matrícula, nombre, carrera, edad, sexo, promedio, asistencia y accesos a Moodle.

El objetivo de esta base de datos fue representar una situación similar a la que podría existir en una universidad real, donde la información no siempre se encuentra completa, correcta o sin repetir. Por esta razón, además de los registros válidos, se agregaron errores intencionales para poder aplicar posteriormente un proceso de limpieza de datos mediante Power Query.

Los campos incluidos en el archivo fueron los siguientes:

Campo	Descripción
Matrícula	Identificador único de cada estudiante.
Nombre	Nombre completo del alumno.
Carrera	Programa académico al que pertenece el estudiante.
Edad	Edad del alumno.
Sexo	Clasificación del alumno como M o F.
Promedio	Calificación general del estudiante.
Asistencia	Porcentaje de asistencia del alumno.
Accesos Moodle	Cantidad de accesos realizados a la plataforma Moodle.

Para simular errores comunes en una base de datos real, se agregaron registros con problemas como edades ilógicas, promedios fuera del rango permitido, campos vacíos, datos categóricos incorrectos, porcentajes inválidos y registros duplicados. Algunos ejemplos de errores incluidos fueron una edad de **250**, un promedio de **110**, un promedio negativo, una asistencia de **130%**, campos vacíos en nombre, carrera y edad, un valor inválido en sexo y matrículas repetidas.

Estos errores fueron agregados de forma intencional para que, en las siguientes fases del proyecto, se pudiera demostrar el proceso ETL, especialmente la etapa de transformación y limpieza de datos. De esta manera, el archivo **alumnos.xlsx** funciona como la fuente original de datos sucios que será procesada para obtener una versión limpia y confiable.

matrícula	nombre	carrera	edad	sexo	promedio	asistencia	accesos_moodle
UTM2020001	Miguel Ángel Ramírez 1	Contaduría	20 F		79.2	85	58
UTM2020002	Natalia Cárdenas 2	Mecatrónica	21 F		87.2	63	77
UTM2020003	Camila Rivera 3	Mecatrónica	18 M		77.1	61	53
UTM2020004	Renata Aguilar 4	Contaduría	20 F		94.8	99	34
UTM2020005	Oscar Treviño 5	Mecatrónica	25 F		74	73	33
UTM2020006	Luis Ángel Pérez 6	Tecnologías de la Información	26 M		69.9	81	21
UTM2020007	Camila Rivera 7	Administración	19 F		89.7	78	20
UTM2020008	Fernanda Campos 8	Procesos Industriales	22 M		94.2	69	22
UTM2020009	Néstor Reyes 9	Procesos Industriales	27 F		96.6	56	26
UTM2020010	Camila Rivera 10	Ingeniería en Desarrollo de Software	23 M		87.1	86	19
UTM2020011	Eduardo Vega 11	Tecnologías de la Información	21 M		98.6	65	53
UTM2020012	Fernando Ortiz 12	Mantenimiento Industrial	22 M		79.3	57	1
UTM2020013	Kevin Medina 13	Mantenimiento Industrial	26 M		90.2	98	66
UTM2020014	Lucía Escobedo 14	Ingeniería en Desarrollo de Software	25 M		85.1	69	51
UTM2020015	Camila Rivera 15	Tecnologías de la Información	19 F		69.4	87	77
UTM2020016	Diana Paredes 16	Ingeniería en Desarrollo de Software	20 F		72.8	60	57
UTM2020017	Lucía Escobedo 17	Administración	26 M		87.6	80	8
UTM2020018	Héctor Salinas 18	Mecatrónica	26 M		98.9	88	47
UTM2020019	David Montoya 19	Ingeniería en Desarrollo de Software	23 F		87.4	80	58
UTM2020020	Sofía Castillo 20	Contaduría	19 M		77	63	38
UTM2020021	Gabriela León 21	Procesos Industriales	21 F		71.9	91	60
UTM2020022	Carlos Hernández 22	Mantenimiento Industrial	18 F		68.1	81	4
UTM2020023	José Luis García 23	Contaduría	22 M		83.5	80	45
UTM2020024	Jorge Alberto Cruz 24	Procesos Industriales	18 M		98.3	56	42
UTM2020025	Lucía Escobedo 25	Ingeniería en Desarrollo de Software	19 M		66.1	93	25
UTM2020026	Melesia Quintanilla 26	Mecatrónica	26 M		90.6	95	63
UTM2020027	David Montoya 27	Mecatrónica	21 M		86.9	71	26
UTM2020028	Fernanda Campos 28	Ingeniería en Desarrollo de Software	22 M		94.3	78	40
UTM2020029	Ximena Navarro 29	Administración	27 M		84.2	62	46
UTM2020030	María Fernanda López 30	Tecnologías de la Información	23 F		82.9	79	21
UTM2020031	Héctor Salinas 31	Tecnologías de la Información	20 M		100.7	55	48
UTM2020032	Ana Sofía Martínez 32	Ingeniería en Desarrollo de Software	26 M		95.1	86	39
UTM2020033	Paola Mendoza 33	Procesos Industriales	27 M		88.4	62	46
UTM2020034	Luis Ángel Pérez 34	Mantenimiento Industrial	20 F		90.4	76	67
UTM2020035	Fernando Ortiz 35	Mantenimiento Industrial	20 M		78.9	79	9
UTM2020036	Lucía Escobedo 36	Procesos Industriales	24 M		89.8	93	35
UTM2020037	Jorge Alberto Cruz 37	Ingeniería en Desarrollo de Software	19 M		90.3	67	78
UTM2020038	Regina Flores 38	Administración	22 F		76	96	38

Figura 1. Archivo alumnos.xlsx con registros de estudiantes y errores intencionales.

6. Fase 2: Identificación de tipos y fuentes

En esta fase se identificaron los tipos y fuentes de datos utilizados en el conjunto de información de los estudiantes. La base de datos contiene campos relacionados con la identificación del alumno, su información académica y su actividad dentro de la plataforma Moodle.

Los datos como matrícula, nombre, carrera, edad y sexo provienen principalmente del Sistema Escolar, ya que corresponden a información general del estudiante. El promedio académico se obtiene del archivo de Excel de Servicios Escolares, mientras que los accesos a Moodle provienen de la plataforma educativa. La asistencia puede obtenerse del sistema de control escolar o de registros internos de clase.

Esta clasificación permite comprender el origen de la información antes de iniciar el proceso de extracción, transformación y carga, facilitando la integración de los datos dentro del Data Warehouse.

7. Fase 3: Extracción de datos

En esta fase se realizó la extracción de los datos desde el archivo original alumnos.xlsx utilizando la herramienta Power Query de Microsoft Excel. El archivo contiene los registros de estudiantes creados previamente, incluyendo información como matrícula, nombre, carrera, edad, sexo, promedio, asistencia y accesos a Moodle.

Para realizar la extracción, se utilizó la opción Obtener datos desde archivo de Excel. Posteriormente, se seleccionó la hoja correspondiente a los alumnos y se eligió la opción Transformar datos, lo que permitió cargar la información dentro del editor de Power Query.

En esta etapa no se realizaron modificaciones ni correcciones sobre los registros, ya que el objetivo fue únicamente importar los datos originales para iniciar el proceso ETL. Los errores intencionales, como valores faltantes, registros duplicados y datos ilógicos, se conservaron para ser tratados en la siguiente fase de limpieza.

	A	B	C	D	E	F	G	H
	matrícula	nombre	carrera	edad	sexo	promedio	asistencia	accesos_moodle
1	UTM2026001	Miguel Ángel Ramírez 1	Contaduría	20 F		76.2	95	58
2	UTM2026002	Natalia Cárdenas 2	Mecánica	21 F		77.2	63	77
3	UTM2026003	Camila Rivera 3	Mecánica	18 M		77.1	61	53
4	UTM2026004	Renata Aguilar 4	Contaduría	20 F		94.8	99	34
5	UTM2026005	Oscar Treviño 5	Mecánica	25 F		74	73	33
6	UTM2026006	Luis Ángel Pérez 6	Tecnologías de la Información	26 M		69.9	51	21
7	UTM2026007	Camila Rivera 7	Administración	19 F		89.7	78	20
8	UTM2026008	Fernanda Campos 8	Procesos Industriales	22 M		94.2	69	22
9	UTM2026009	Alejandro Reyes 9	Procesos Industriales	27 F		90.6	54	28
10	UTM2026010	Camila Rivera 10	Ingeniería en Desarrollo de Software	23 M		87.1	90	19
11	UTM2026011	Eduardo Vega 11	Tecnologías de la Información	21 M		98.6	65	53
12	UTM2026012	Fernando Cortez 12	Mantenimiento Industrial	22 M		76.3	57	35
13	UTM2026013	Xosin Medina 13	Mantenimiento Industrial	26 M		90.2	99	66
14	UTM2026014	Lucía Escobedo 14	Ingeniería en Desarrollo de Software	25 M		85.1	69	51
15	UTM2026015	Camila Rivera 15	Tecnologías de la Información	19 F		69.4	87	77
16	UTM2026016	Diana Paredes 16	Ingeniería en Desarrollo de Software	20 F		72.9	60	57
17	UTM2026017	Lucía Escobedo 17	Administración	26 M		87.6	80	5
18	UTM2026018	Héctor Salinas 18	Mecánica	26 M		98.9	88	47
19	UTM2026019	David Montoya 19	Ingeniería en Desarrollo de Software	23 F		87.4	80	58
20	UTM2026020	Sofía Castillo 20	Contaduría	19 M		77	63	38
21	UTM2026021	Gabriela León 21	Procesos Industriales	21 F		71.9	91	60
22	UTM2026022	Carlos Hernández 22	Mantenimiento Industrial	18 F		66.1	81	4
23	UTM2026023	José Luis García 23	Contaduría	22 M		83.5	80	45
24	UTM2026024	Jorge Alberto Cruz 24	Procesos Industriales	19 M		98.3	56	42
25	UTM2026025	Lucía Escobedo 25	Ingeniería en Desarrollo de Software	19 M		66.1	93	25
26	UTM2026026	Melissa Quintanilla 26	Mecánica	26 M		90.6	95	63
27	UTM2026027	David Montoya 27	Mecánica	21 M		86.9	71	26
28	UTM2026028	Fernanda Campos 28	Ingeniería en Desarrollo de Software	22 M		94.3	75	40
29	UTM2026029	Ximena Navarro 29	Administración	27 M		94.2	82	40
30	UTM2026030	María Fernanda López 30	Tecnologías de la Información	23 F		82.9	79	21
31	UTM2026031	Héctor Salinas 31	Tecnologías de la Información	20 M		100.7	55	48
32	UTM2026032	Ara Sofía Martínez 32	Ingeniería en Desarrollo de Software	26 M		95.1	86	39
33	UTM2026033	Paola Mendoza 33	Procesos Industriales	27 M		88.4	62	49
34	UTM2026034	Luis Ángel Pérez 34	Mantenimiento Industrial	20 F		90.4	76	67
35	UTM2026035	Fernando Cortez 35	Mantenimiento Industrial	20 M		79.9	79	6
36	UTM2026036	Lucía Escobedo 36	Procesos Industriales	24 M		86.8	93	35
37	UTM2026037	Jorge Alberto Cruz 37	Ingeniería en Desarrollo de Software	19 M		90.3	67	78
38	UTM2026038	Regina Flores 38	Administración	22 F		76	96	38

Figura 2. Archivo alumnos.xlsx con los datos originales de los estudiantes.

matricula	nombre	carrera	edad	sexo	promedio	sueldo
UTM2020001	Miguel Ángel Ramírez 1	Contaduría	20	F	76.2	95
UTM2020002	Natalia Cárdenas 2	Mecatrónica	21	F	87.2	63
UTM2020003	Camila Rivera 3	Mecatrónica	18	M	27.1	82
UTM2020004	Isabella Aguilar 4	Contaduría	20	F	94.8	39
UTM2020005	Oscar Treviño 5	Mecatrónica	25	F	74	73
UTM2020006	Luis Ángel Pérez 6	Tecnologías de la Información	26	M	69.9	82
UTM2020007	Camila Rivera 7	Administración	19	F	89.7	78
UTM2020008	Fernando Campos 8	Procesos Industriales	22	M	84.2	69
UTM2020009	Alexander Reyes 9	Procesos Industriales	27	F	86.6	36
UTM2020010	Camila Rivera 10	Ingeniería en Desarrollo de Software	23	M	87.1	86
UTM2020011	Eduardo Vega 11	Tecnologías de la Información	22	M	88.6	83
UTM2020012	Fernando Ortiz 12	Mantenimiento Industrial	22	M	76.3	57
UTM2020013	Kevin Medina 13	Mantenimiento Industrial	26	M	90.2	86
UTM2020014	Lucía Escobedo 14	Ingeniería en Desarrollo de Software	25	M	85.1	69
UTM2020015	Camila Rivera 15	Tecnologías de la Información	19	F	69.4	87
UTM2020016	Diana Paredes 16	Ingeniería en Desarrollo de Software	20	F	72.8	60
UTM2020017	Lucía Escobedo 17	Administración	26	M	87.6	80
UTM2020018	Héctor Salinas 18	Mecatrónica	26	M	88.9	88
UTM2020019	David Martínez 19	Ingeniería en Desarrollo de Software	23	F	87.4	80
UTM2020020	Sofía Castillo 20	Contaduría	19	M	77	43
UTM2020021	Gabriela León 21	Procesos Industriales	22	F	71.9	91
UTM2020022	Carlos Hernández 22	Mantenimiento Industrial	18	F	66.1	82
UTM2020023	José Luis García 23	Contaduría	22	M	83.5	80
UTM2020024	Jorge Alberto Cruz 24	Procesos Industriales	18	M	86.9	86
UTM2020025	Lucía Escobedo 25	Ingeniería en Desarrollo de Software	19	M	86.1	93
UTM2020026	Melissa Quintanilla 26	Mecatrónica	26	M	90.6	95
UTM2020027	David Montoya 27	Mecatrónica	21	M	86.9	71
UTM2020028	Fernando Campos 28	Ingeniería en Desarrollo de Software	22	M	84.3	78
UTM2020029	Ximena Navarro 29	Administración	27	M	84.2	82
UTM2020030	María Fernanda López 30	Tecnologías de la Información	23	F	82.9	79
UTM2020031	Héctor Salinas 31	Tecnologías de la Información	20	M	300.7	53
UTM2020032	Ana Sofía Martínez 32	Ingeniería en Desarrollo de Software	26	M	95.1	86
UTM2020033	Paola Mendoza 33	Procesos Industriales	27	M	88.4	62
UTM2020034	Luis Ángel Pérez 34	Mantenimiento Industrial	20	F	90.4	76
UTM2020035	Fernando Ortiz 35	Mantenimiento Industrial	26	M	79.9	8
UTM2020036	Lucía Escobedo 36	Procesos Industriales	24	M	86.8	93
UTM2020037	Jorge Alberto Cruz 37	Ingeniería en Desarrollo de Software	19	M	80.3	67
UTM2020038	Regina Flores 38	Administración	22	F	76	86
UTM2020039	Isabella Aguilar 39	Contaduría	20	F	94.8	39

Figura 3. Extracción de datos desde Excel mediante Power Query.

[↑ Regresar al índice](#)

8. Fase 4: Transformación y limpieza de datos

En esta fase se realizó la limpieza de los datos utilizando Power Query. El objetivo fue corregir los errores intencionales incluidos en el archivo original *alumnos.xlsx*, simulando problemas comunes que pueden presentarse en una base de datos real.

Durante el proceso se eliminaron registros duplicados tomando como referencia la matrícula del alumno. También se corrigieron valores ilógicos, como edades fuera de rango, promedios mayores a 100, asistencias superiores al 100% y accesos negativos a Moodle. Los campos vacíos fueron completados con valores representativos o etiquetas como “No especificado”, según el tipo de dato correspondiente.

Además, se creó una nueva columna llamada *nivel_academico*, la cual clasifica a los estudiantes de acuerdo con su promedio. Los alumnos con promedio entre 90 y 100 fueron clasificados como “Excelente”, entre 80 y 89 como “Bueno”, entre 70 y 79 como “Regular” y los menores a 70 como “Riesgo”.

Como resultado de esta fase, se obtuvo un conjunto de datos limpio y estructurado, listo para ser exportado como *alumnos_limpios.csv* y utilizado posteriormente en la carga del Data Warehouse.

Regla de limpieza	Criterio	Resultado esperado
Promedio	90-100	Excelente
Promedio	80-89	Bueno
Promedio	70-79	Regular
Promedio	Menor a 70	Riesgo

8.1 Comparación antes y después

Table: TransformColumnTypes (TablaAlumnosOriginales)

matricula	nombre	carrera	edad	sexo	1.2 promedio	% asistencia	% accesos_moodle
UTM2026001	Miguel Ángel Ramírez 1	Contaduría	20	F	76.2	95	59
UTM2026002	Natalia Cárdenas 2	Mecatrónica	21	F	87.2	63	77
UTM2026003	Camila Rivera 3	Mecatrónica	18	M	77.1	61	53
UTM2026004	Renata Aguilar 4	Contaduría	20	F	94.8	99	84
UTM2026005	Oscar Treviño 5	Mecatrónica	25	F	74	73	33
UTM2026006	Luis Ángel Pérez 6	Tecnologías de la Información	26	M	69.9	81	21
UTM2026007	Camila Rivera 7	Administración	19	F	89.7	78	20
UTM2026008	Fernanda Campos 8	Procesos Industriales	22	M	94.2	69	22
UTM2026009	Alejandro Reyes 9	Procesos Industriales	27	F	96.6	56	28
UTM2026010	Camila Rivera 10	Ingeniería en Desarrollo de Software	23	M	87.1	86	19
UTM2026011	Eduardo Vega 11	Tecnologías de la Información	21	M	98.6	65	53
UTM2026012	Fernando Ortiz 12	Mantenimiento Industrial	22	M	76.3	57	1
UTM2026013	Kevin Medina 13	Mantenimiento Industrial	26	M	90.2	98	66
UTM2026014	Lucia Escobedo 14	Ingeniería en Desarrollo de Software	25	M	85.1	69	51
UTM2026015	Camila Rivera 15	Tecnologías de la Información	19	F	69.4	87	77
UTM2026016	Diana Paredes 16	Ingeniería en Desarrollo de Software	20	F	72.8	60	57
UTM2026017	Lucia Escobedo 17	Administración	26	M	87.6	80	8
UTM2026018	Héctor Salinas 18	Mecatrónica	26	M	98.9	88	47
UTM2026019	David Montoya 19	Ingeniería en Desarrollo de Software	23	F	87.4	80	59
UTM2026020	Sofia Castillo 20	Contaduría	19	M	77	63	38
UTM2026021	Gabriela León 21	Procesos Industriales	21	F	71.9	91	60
UTM2026022	Carlos Hernández 22	Mantenimiento Industrial	18	F	66.1	81	4
UTM2026023	José Luis García 23	Contaduría	22	M	83.5	80	45
UTM2026024	Jorge Alberto Cruz 24	Procesos Industriales	18	M	98.3	56	42
UTM2026025	Lucia Escobedo 25	Ingeniería en Desarrollo de Software	19	M	66.1	93	25
UTM2026026	Melissa Quintanilla 26	Mecatrónica	26	M	90.6	95	63
UTM2026027	David Montoya 27	Mecatrónica	21	M	86.9	71	26
UTM2026028	Fernanda Campos 28	Ingeniería en Desarrollo de Software	22	M	94.3	78	40

Figura 4. Tabla original en power query sin matrículas duplicadas.

Agregar una columna condicional

Agregue una columna condicional que se calcula a partir de las otras columnas o valores.

Nuevo nombre de columna

nivel_academico

Nombre de columna	Operador	Valor	Salida
Si promedio	es mayor o igual...	90	Excelente
O si promedio	es mayor o igual...	80	Bueno
O si promedio	es mayor o igual...	70	Regular
O si promedio	es menor que	70	Riesgo

Agregar cláusula

De lo contrario

Aceptar

Cancelar

Figura 5. Adición de columna nueva

matrícula	nombre	carrera	edad	sexo	promedio	asistencia	accesos_moodle	nivel_academico
UTM2026001	Miguel Ángel Ramírez 1	Contaduría	20	F	76.2	95	59	Regular
UTM2026002	Natalia Cárdenas 2	Mecatrónica	21	F	87.2	63	77	Bueno
UTM2026003	Camila Rivera 3	Mecatrónica	18	M	77.1	61	53	Regular
UTM2026004	Renata Aguilar 4	Contaduría	20	F	94.8	99	34	Excelente
UTM2026005	Oscar Treviño 5	Mecatrónica	25	F	74	73	33	Regular
UTM2026006	Luis Ángel Pérez 6	Tecnologías de la Información	26	M	69.9	81	21	Riesgo
UTM2026007	Camila Rivera 7	Administración	19	F	89.7	78	20	Bueno
UTM2026008	Fernanda Campos 8	Procesos Industriales	22	M	94.2	69	22	Excelente
UTM2026009	Alejandro Reyes 9	Procesos Industriales	27	F	96.6	56	28	Excelente
UTM2026010	Camila Rivera 10	Ingeniería en Desarrollo de Software	23	M	87.1	86	19	Bueno
UTM2026011	Eduardo Vega 11	Tecnologías de la Información	21	M	98.6	65	53	Excelente
UTM2026012	Fernando Ortiz 12	Mantenimiento Industrial	22	M	76.3	57	1	Regular
UTM2026013	Kevin Medina 13	Mantenimiento Industrial	26	M	90.2	98	66	Excelente
UTM2026014	Lucía Escobedo 14	Ingeniería en Desarrollo de Software	25	M	85.1	69	51	Bueno
UTM2026015	Camila Rivera 15	Tecnologías de la Información	19	F	69.4	87	77	Riesgo
UTM2026016	Diana Paredes 16	Ingeniería en Desarrollo de Software	20	F	72.8	60	57	Regular
UTM2026017	Lucía Escobedo 17	Administración	26	M	87.6	80	8	Bueno
UTM2026018	Héctor Salinas 18	Mecatrónica	26	M	98.9	88	47	Excelente
UTM2026019	David Montoya 19	Ingeniería en Desarrollo de Software	23	F	87.4	80	59	Bueno
UTM2026020	Sofía Castillo 20	Contaduría	19	M	77	63	38	Regular
UTM2026021	Gabriela León 21	Procesos Industriales	21	F	71.9	91	60	Regular
UTM2026022	Carlos Hernández 22	Mantenimiento Industrial	18	F	66.1	81	4	Riesgo
UTM2026023	José Luis García 23	Contaduría	22	M	83.5	80	45	Bueno
UTM2026024	Jorge Alberto Cruz 24	Procesos Industriales	18	M	98.3	56	42	Excelente
UTM2026025	Lucía Escobedo 25	Ingeniería en Desarrollo de Software	19	M	66.1	93	25	Riesgo
UTM2026026	Melissa Quintanilla 26	Mecatrónica	26	M	90.6	95	63	Excelente
UTM2026027	David Montoya 27	Mecatrónica	21	M	86.9	71	26	Bueno
UTM2026028	Lucía Escobedo 28	Ingeniería en Desarrollo de Software	22	M	94.3	78	40	Excelente

Figura 6. Tabla con datos limpios.

[↑ Regresar al índice](#)

9. Fase 5: Diseño del Data Warehouse

En esta fase se diseñó el modelo del Data Warehouse mediante un esquema estrella. Este tipo de modelo permite organizar la información académica de los estudiantes en una tabla central de hechos y varias tablas de dimensiones relacionadas.

La tabla central del modelo se denomina *Hechos_Rendimiento*, ya que almacena los indicadores principales para el análisis académico, como promedio, asistencia, accesos a Moodle y nivel académico. Estos datos permiten evaluar el rendimiento de los estudiantes y detectar posibles casos de riesgo académico.

Alrededor de la tabla de hechos se definieron las dimensiones *Dim_Alumno*, *Dim_Carrera*, *Dim_Tiempo*, *Dim_Materia* y *Dim_Profesor*. Estas dimensiones permiten analizar la información desde diferentes perspectivas, como alumno, carrera, periodo académico, materia y profesor.

El esquema estrella facilita la consulta de información y permite responder preguntas relacionadas con el rendimiento académico, como qué carrera presenta mayor índice de reprobación, qué alumnos tienen bajo desempeño o si existe relación entre la asistencia y el promedio.




Figura 7. Diagrama de Estrella

Tabla	Tipo	Campos principales
Hechos_Rendimiento	Hechos	promedio, asistencia, accesos_moodle, nivel_academico
Dim_Alumno	Dimensión	matricula, nombre, edad, sexo
Dim_Carrera	Dimensión	nombre_carrera
Dim_Tiempo	Dimensión	semestre, periodo, anio
Dim_Materia	Dimensión	nombre_materia
Dim_Profesor	Dimensión	nombre_profesor

[↑ Regresar al índice](#)

10. Fase 6: Configuración del Data Warehouse

En esta fase se realizó la configuración del Data Warehouse utilizando MySQL Workbench. Se creó una base de datos llamada *universidad_dw*, empleando el motor de almacenamiento InnoDB y codificación UTF-8 para permitir el manejo correcto de caracteres.

Posteriormente, se crearon las tablas correspondientes al esquema estrella diseñado previamente. La tabla central *hechos_rendimiento* almacena los indicadores principales del rendimiento académico, mientras que las dimensiones *dim_alumno*, *dim_carrera*, *dim_tiempo*, *dim_materia* y *dim_profesor* permiten analizar la información desde diferentes perspectivas.

También se definieron llaves primarias y llaves foráneas para mantener la relación entre la tabla de hechos y las dimensiones del Data Warehouse.

Parámetro	Valor
Nombre de la base de datos	universidad_dw
Motor	InnoDB

Codificación	UTF8
Puerto	3306
Servidor	localhost
Usuario	root




Figura 7. Captura de script en MySQL Workbench.

10.1 Script SQL

DROP DATABASE IF EXISTS universidad_dw;

CREATE DATABASE universidad_dw

CHARACTER SET utf8mb4

COLLATE utf8mb4_general_ci;

USE universidad_dw;

CREATE TABLE dim_alumno (

id_alumno INT PRIMARY KEY AUTO_INCREMENT,

matricula VARCHAR(20) NOT NULL,

nombre VARCHAR(100) NOT NULL,

edad INT NOT NULL,

sexo VARCHAR(20) NOT NULL

) ENGINE = InnoDB;

CREATE TABLE dim_carrera (

id_carrera INT PRIMARY KEY AUTO_INCREMENT,

```

    nombre_carrera VARCHAR(100) NOT NULL
) ENGINE = InnoDB;

```

```

CREATE TABLE dim_tiempo (
    id_tiempo INT PRIMARY KEY AUTO_INCREMENT,
    semestre INT NOT NULL,
    periodo VARCHAR(50) NOT NULL,
    anio INT NOT NULL
) ENGINE = InnoDB;

```

```

CREATE TABLE dim_materia (
    id_materia INT PRIMARY KEY AUTO_INCREMENT,
    nombre_materia VARCHAR(100) NOT NULL
) ENGINE = InnoDB;

```

```

CREATE TABLE dim_profesor (
    id_profesor INT PRIMARY KEY AUTO_INCREMENT,
    nombre_profesor VARCHAR(100) NOT NULL
) ENGINE = InnoDB;

```

```

CREATE TABLE hechos_rendimiento (
    id_hecho INT PRIMARY KEY AUTO_INCREMENT,
    id_alumno INT NOT NULL,
    id_carrera INT NOT NULL,
    id_tiempo INT NOT NULL,
    id_materia INT NOT NULL,
    id_profesor INT NOT NULL,
    promedio DECIMAL(5,2) NOT NULL,
    asistencia DECIMAL(5,2) NOT NULL,
    accesos_moodle INT NOT NULL,
    nivel_academico VARCHAR(20) NOT NULL,

```

```

CONSTRAINT fk_hechos_alumno
    FOREIGN KEY (id_alumno)

```

```

REFERENCES dim_alumno(id_alumno),

CONSTRAINT fk_hechos_carrera
    FOREIGN KEY (id_carrera)
    REFERENCES dim_carrera(id_carrera),

CONSTRAINT fk_hechos_tiempo
    FOREIGN KEY (id_tiempo)
    REFERENCES dim_tiempo(id_tiempo),

CONSTRAINT fk_hechos_materia
    FOREIGN KEY (id_materia)
    REFERENCES dim_materia(id_materia),

CONSTRAINT fk_hechos_profesor
    FOREIGN KEY (id_profesor)
    REFERENCES dim_profesor(id_profesor)
) ENGINE = InnoDB;
```

[↑ Regresar al índice](#)

11. Fase 7: Carga de datos

En esta fase se realizó la carga de los datos limpios al Data Warehouse utilizando MySQL Workbench. El archivo alumnos_limpios.csv, generado después del proceso de limpieza en Power Query, fue utilizado como fuente de datos para alimentar una tabla auxiliar llamada alumnos_limpios.

Inicialmente se intentó realizar la importación mediante el asistente Table Data Import Wizard de MySQL Workbench. Sin embargo, debido a problemas de codificación del archivo CSV, se optó por realizar la carga mediante el comando SQL LOAD DATA LOCAL INFILE, lo cual permitió importar correctamente los registros.

La tabla auxiliar alumnos_limpios fue utilizada como una zona temporal de carga. Posteriormente, los datos fueron distribuidos hacia las tablas del esquema estrella. La información de los estudiantes se cargó en dim_alumno, las carreras en dim_carrera, y los indicadores académicos como promedio, asistencia, accesos a Moodle y nivel académico fueron cargados en la tabla de hechos hechos_rendimiento.

Debido a que el archivo limpio no contenía información específica de periodo, materia ni profesor, las dimensiones dim_tiempo, dim_materia y dim_profesor fueron cargadas con datos complementarios para completar el modelo estrella solicitado en el proyecto. De esta manera, se mantuvo el archivo limpio original sin modificarlo y se logró integrar la información dentro del Data Warehouse.

```

1 • USE universidad_dw;
2 • LOAD DATA LOCAL INFILE 'C:/Users/bdavi/Documents/Escuela/Noveno/Extraccion_bd/alumnos_limpios.csv'
3 INTO TABLE alumnos_limpios
4 CHARACTER SET utf8mb4
5 FIELDS TERMINATED BY ','
6 ENCLOSED BY '"'
7 LINES TERMINATED BY '\r\n'
8 IGNORE 1 ROWS
9 (matricula, nombre, carrera, edad, sexo, promedio, asistencia, accesos_moodle, nivel_academico);

```

Figura 8. Captura de script para importar los datos de alumnos_limpios.csv.

Result Grid

matricula	nombre	carrera	edad	sexo	promedio	asistencia	accesos_moodle	nivel_academico
UTM2026096	Oscar Treviño 56	Contaduría	22	F	94.30	98.00	50	Excelente
UTM2026057	Eduardo Vega 57	Contaduría	24	F	83.20	71.00	18	Bueno
UTM2026058	Jorge Alberto Cruz 58	Administración	24	F	62.30	71.00	15	Riesgo
UTM2026059	Héctor Salinas 59	Tecnologías de la Información	22	F	80.40	61.00	11	Bueno
UTM2026060	Miguel Ángel Ramírez 60	Mecatrónica	26	F	99.00	85.00	2	Excelente
UTM2026061	Jesús Villanueva 61	Contaduría	23	M	62.90	88.00	26	Riesgo
UTM2026062	Sofía Castillo 62	Mantenimiento Industrial	20	F	92.90	75.00	73	Excelente
UTM2026063	Héctor Salinas 63	Ingeniería en Desarrollo de Software	18	M	97.10	65.00	3	Excelente
UTM2026064	Valeria Rodríguez 64	Administración	18	F	85.40	61.00	11	Bueno
UTM2026065	Ana Sofía Martínez 65	Ingeniería en Desarrollo de Software	25	F	86.80	65.00	74	Bueno
UTM2026066	Brandon Herrera 66	Mecatrónica	22	F	66.00	59.00	45	Riesgo
UTM2026067	Daniel Gómez 67	Tecnologías de la Información	20	F	65.90	81.00	79	Riesgo
UTM2026068	Natalia Cárdenas 68	Administración	26	M	77.30	56.00	42	Regular
UTM2026069	Kevin Medina 69	Procesos Industriales	22	M	78.20	66.00	6	Regular
UTM2026070	Melissa Quintanilla 70	Procesos Industriales	22	F	85.20	69.00	29	Bueno
UTM2026071	Emiliano Sánchez 71	Mantenimiento Industrial	19	F	84.00	95.00	16	Bueno
UTM2026072	Ricardo Vargas 72	Administración	22	F	85.00	74.00	62	Bueno
UTM2026073	Kevin Medina 73	Tecnologías de la Información	27	F	84.40	67.00	78	Bueno
UTM2026074	Sebastián Fuentes 74	Ingeniería en Desarrollo de Software	27	F	66.50	75.00	7	Riesgo
UTM2026075	Paola Mendoza 75	Tecnologías de la Información	23	M	67.00	58.00	41	Riesgo
UTM2026076	Héctor Salinas 76	Mecatrónica	21	M	75.20	57.00	12	Regular
UTM2026077	Alejandro Reyes 77	Ingeniería en Desarrollo de Software	20	M	69.90	91.00	30	Riesgo
UTM2026078	Oscar Treviño 78	Contaduría	18	M	90.70	93.00	56	Excelente
UTM2026079	Fernanda Campos 79	Mecatrónica	27	F	66.50	77.00	67	Riesgo
UTM2026080	Oscar Treviño 80	Mantenimiento Industrial	27	M	100.00	99.00	61	Excelente
UTM2026081	Daniel Gómez 81	Tecnologías de la Información	20	F	84.20	94.00	42	Bueno
UTM2026082	Ximena Navarro 82	Mecatrónica	25	M	75.00	66.00	36	Regular
UTM2026083	Roberto Ibarra 83	Contaduría	25	F	76.40	74.00	69	Regular
UTM2026084	Miguel Ángel Ramírez 84	Mantenimiento Industrial	23	M	70.80	80.00	58	Regular
UTM2026085	David Montoya 85	Contaduría	23	F	68.50	100.00	26	Riesgo
UTM2026086	Ricardo Vargas 86	Mantenimiento Industrial	18	M	99.60	60.00	16	Excelente

Figura 9. Captura de tabla alumnos_limpios con datos importados.

Result Grid

matricula	nombre	nombre_carrera	semestre	periodo	nombre_materia	nombre_profesor	promedio	asistencia	accesos_moodle	nivel_academico
UTM2026001	Miguel Ángel Ramírez 1	Contaduría	1	Enero-Abril	Base de Datos	Luis Martínez	76.20	95.00	99	Regular
UTM2026004	Rosita Aguilar 4	Contaduría	1	Enero-Abril	Inglés	María González	94.80	99.00	34	Excelente
UTM2026007	Carla Rivera 7	Administración	1	Enero-Abril	Programación	Ana Rodríguez	89.70	78.00	20	Bueno
UTM2026010	Carla Rivera 10	Ingeniería en Desarrollo de Software	1	Enero-Abril	Riesgos	Jorge Ramírez	87.10	86.00	19	Bueno
UTM2026013	Kevin Medina 13	Mantenimiento Industrial	1	Enero-Abril	Matemáticas	Carlos Hernández	90.20	98.00	66	Excelente
UTM2026016	Diana Paredes 16	Ingeniería en Desarrollo de Software	1	Enero-Abril	Base de Datos	Luis Martínez	72.80	60.00	57	Regular
UTM2026019	David Montoya 19	Ingeniería en Desarrollo de Software	1	Enero-Abril	Inglés	María González	87.40	80.00	99	Bueno
UTM2026022	Carlos Hernández 22	Mantenimiento Industrial	1	Enero-Abril	Programación	Ana Rodríguez	66.10	81.00	4	Riesgo
UTM2026025	Luis Escobedo 25	Ingeniería en Desarrollo de Software	1	Enero-Abril	Riesgos	Jorge Ramírez	66.10	93.00	25	Riesgo
UTM2026028	Fernanda Campos 28	Ingeniería en Desarrollo de Software	1	Enero-Abril	Matemáticas	Carlos Hernández	94.30	78.00	40	Excelente
UTM2026031	Héctor Salinas 31	Tecnologías de la Información	1	Enero-Abril	Base de Datos	Luis Martínez	100.00	55.00	48	Excelente
UTM2026034	Luis Ángel Pérez 34	Mantenimiento Industrial	1	Enero-Abril	Inglés	María González	90.40	76.00	67	Excelente
UTM2026037	Jorge Alberto Cruz 37	Ingeniería en Desarrollo de Software	1	Enero-Abril	Programación	Ana Rodríguez	90.30	67.00	78	Excelente
UTM2026040	Rosita Aguilar 40	Contaduría	1	Enero-Abril	Riesgos	Jorge Ramírez	66.40	78.00	53	Riesgo
UTM2026043	Carlos Hernández 43	Mecatrónica	1	Enero-Abril	Matemáticas	Carlos Hernández	82.60	71.00	13	Bueno
UTM2026046	Paola Mendoza 46	Procesos Industriales	1	Enero-Abril	Base de Datos	Luis Martínez	79.50	96.00	62	Regular
UTM2026049	Alfredo Reyes 49	Mecatrónica	1	Enero-Abril	Inglés	María González	97.50	68.00	42	Excelente
UTM2026052	Roberto Ibarra 52	Tecnologías de la Información	1	Enero-Abril	Programación	Ana Rodríguez	87.80	98.00	71	Bueno
UTM2026055	Fernanda Campos 55	Administración	1	Enero-Abril	Riesgos	Jorge Ramírez	68.00	61.00	19	Riesgo
UTM2026058	Jorge Alberto Cruz 58	Administración	1	Enero-Abril	Matemáticas	Carlos Hernández	62.30	71.00	15	Riesgo

Figura 10. Captura de tabla JOIN de tablas para ver los registros completos con tablas auxiliares.

[↑ Regresar al índice](#)

12. Fase 8: Repositorio del proyecto

En esta fase se creó el repositorio del proyecto con el objetivo de organizar y entregar todos los archivos generados durante el desarrollo del Data Warehouse. El repositorio contiene los datos originales, los datos procesados, el script SQL, el diagrama del esquema estrella, la documentación final y el archivo README.

Enlace al repositorio:

<https://github.com/DavidCM28/UTM-DataWarehouse.git>

La estructura del repositorio se organizó de la siguiente manera:

Carpeta/archivo	Contenido
DatosOriginales/alumnos.xlsx	Base original con errores intencionales
DatosProcesados/alumnos_limpios.csv	Datos limpios exportados desde Power Query
DataWarehouse/ScriptSQL.sql	Script para crear la base de datos
Diagramas/esquema_estrella.png	Diagrama estrella del Data Warehouse
Documentacion/Reporte.pdf	Documento técnico final
README.md	Descripción, herramientas e integrantes



Esta organización permite mantener separados los archivos originales, los datos procesados y los elementos técnicos del Data Warehouse. Además, facilita la revisión del proyecto, ya que cada carpeta contiene una parte específica del proceso ETL y de la implementación realizada.






[↑ Regresar al índice](#)

13. Evidencias del proceso ETL

En esta sección se presentan las capturas más importantes del proceso ETL realizado durante el desarrollo del Data Warehouse. Las evidencias muestran el estado inicial de los datos, su extracción en Power Query, el proceso de limpieza, la exportación del archivo limpio y la carga final en MySQL Workbench.

El proceso ETL permitió transformar una base original con errores intencionales en un conjunto de datos limpio y estructurado, listo para ser utilizado dentro del Data Warehouse académico.

No.	Evidencia	Descripción	Estado
1	Datos originales		Completado
2	Extracción en Power Query		Completado

3	Eliminación de duplicados		Completado
4	Corrección de valores inválidos		Completado
5	Creación de Nivel Académico		Completado
6	Exportación a CSV		Completado
7	Importación en MySQL	<pre> 1 • USE universidad_dw; 2 • LOAD DATA LOCAL INFILE 'C:/Users/bdavi/Documents/Escuela/Noveno/Extraccion_bd/alumnos_limpios.csv' 3 INTO TABLE alumnos_limpios 4 CHARACTER SET utf8mb4 5 FIELDS TERMINATED BY ',' 6 ENCLOSED BY '"' 7 LINES TERMINATED BY '\r\n' 8 IGNORE 1 ROWS 9 (matricula, nombre, carrera, edad, sexo, promedio, asistencia, accesos_moodle, nivel_academico); </pre>	Completado
8	Consulta de validación		Completado

[↑ Regresar al índice](#)

14. Resultados esperados y consultas de análisis

En esta sección se presentan algunas consultas SQL que permiten analizar la información cargada en el Data Warehouse. Estas consultas están relacionadas con las preguntas planteadas en el caso de estudio,

como identificar carreras con mayor índice de reprobación, alumnos en riesgo académico, materias con menor rendimiento y la relación entre asistencia y promedio.

Las consultas se realizaron utilizando las tablas del esquema estrella: hechos_rendimiento, dim_alumno, dim_carrera, dim_tiempo, dim_materia y dim_profesor.

14.1 Carreras con mayor cantidad de alumnos en riesgo

Esta consulta permite identificar qué carreras tienen más alumnos clasificados con nivel académico **Riesgo**.

```
SELECT
    c.nombre_carrera,
    COUNT(*) AS alumnos_en_riesgo
FROM hechos_rendimiento h
INNER JOIN dim_carrera c
    ON h.id_carrera = c.id_carrera
WHERE h.nivel_academico = 'Riesgo'
GROUP BY c.nombre_carrera
ORDER BY alumnos_en_riesgo DESC;
```

Resultado esperado:

Se obtiene una lista de carreras ordenadas desde la que tiene más alumnos en riesgo hasta la que tiene menos. Esta consulta ayuda a detectar áreas académicas donde podrían necesitarse estrategias de apoyo o regularización.

14.2 Promedio general por carrera

Esta consulta calcula el promedio académico general de cada carrera.

```
SELECT
    c.nombre_carrera,
    ROUND(AVG(h.promedio), 2) AS promedio_general
FROM hechos_rendimiento h
INNER JOIN dim_carrera c
    ON h.id_carrera = c.id_carrera
GROUP BY c.nombre_carrera
ORDER BY promedio_general DESC;
```

Resultado esperado:

Se muestra el promedio general por carrera, permitiendo identificar qué carreras presentan mejor rendimiento académico y cuáles requieren mayor atención.

14.3 Relación entre asistencia y promedio

Esta consulta permite observar la asistencia promedio y el promedio académico por carrera.

```

SELECT
    c.nombre_carrera,
    ROUND(AVG(h.asistencia), 2) AS asistencia_promedio,
    ROUND(AVG(h.promedio), 2) AS promedio_academico
FROM hechos_rendimiento h
INNER JOIN dim_carrera c
    ON h.id_carrera = c.id_carrera
GROUP BY c.nombre_carrera
ORDER BY promedio_academico DESC;

```

Resultado esperado:

Se puede analizar si las carreras con mayor asistencia también presentan mejores promedios. Esto ayuda a observar una posible relación entre la asistencia de los estudiantes y su desempeño académico.

Consulta algo más directa por alumno:

```

SELECT
    a.matricula,
    a.nombre,
    c.nombre_carrera,
    h.asistencia,
    h.promedio,
    h.nivel_academico
FROM hechos_rendimiento h
INNER JOIN dim_alumno a
    ON h.id_alumno = a.id_alumno
INNER JOIN dim_carrera c
    ON h.id_carrera = c.id_carrera
ORDER BY h.asistencia DESC;

```

Resultado esperado:

Se visualizan los alumnos junto con su asistencia y promedio, lo que permite revisar casos específicos donde baja asistencia podría coincidir con bajo rendimiento.

14.4 Materias con menor rendimiento

Esta consulta identifica las materias con menor promedio académico.

```

SELECT
    m.nombre_materia,
    ROUND(AVG(h.promedio), 2) AS promedio_materia
FROM hechos_rendimiento h

```

```
INNER JOIN dim_materia m
  ON h.id_materia = m.id_materia
GROUP BY m.nombre_materia
ORDER BY promedio_materia ASC;
```

Resultado esperado:

Se obtiene una lista de materias ordenadas desde la de menor rendimiento hasta la de mayor rendimiento. Esto permite detectar asignaturas donde los alumnos presentan más dificultades.

14.5 Cantidad de alumnos por nivel académico

Esta consulta muestra cuántos alumnos existen en cada categoría de rendimiento.

```
SELECT
  nivel_academico,
  COUNT(*) AS cantidad_alumnos
FROM hechos_rendimiento
GROUP BY nivel_academico
ORDER BY cantidad_alumnos DESC;
```

Resultado esperado:

Permite conocer la distribución general de los alumnos entre las categorías **Excelente, Bueno, Regular y Riesgo**.

14.6 Consulta general del Data Warehouse

Esta consulta integra las dimensiones con la tabla de hechos para mostrar una vista completa del rendimiento académico.

```
SELECT
  a.matricula,
  a.nombre,
  c.nombre_carrera,
  t.semestre,
  t.periodo,
  m.nombre_materia,
  p.nombre_profesor,
  h.promedio,
  h.asistencia,
  h.accesos_moodle,
  h.nivel_academico
FROM hechos_rendimiento h
INNER JOIN dim_alumno a
```

```

ON h.id_alumno = a.id_alumno
INNER JOIN dim_carrera c
ON h.id_carrera = c.id_carrera
INNER JOIN dim_tiempo t
ON h.id_tiempo = t.id_tiempo
INNER JOIN dim_materia m
ON h.id_materia = m.id_materia
INNER JOIN dim_profesor p
ON h.id_profesor = p.id_profesor
LIMIT 20;

```

Resultado esperado:

Se obtiene una vista integrada de los datos del Data Warehouse, mostrando alumno, carrera, periodo, materia, profesor, promedio, asistencia, accesos a Moodle y nivel académico.

Las consultas anteriores permiten comprobar que el Data Warehouse puede utilizarse para analizar el rendimiento académico de los estudiantes desde diferentes perspectivas. A través del esquema estrella es posible consultar información por carrera, materia, alumno, periodo y nivel académico, facilitando la identificación de alumnos en riesgo, áreas con bajo rendimiento y posibles relaciones entre asistencia y promedio.

[↑ Regresar al índice](#)

15. Conclusiones

El desarrollo de este proyecto permitió comprender la importancia de integrar datos provenientes de diferentes fuentes para convertirlos en información útil y organizada. A partir de una base original de estudiantes con errores intencionales, se simuló una situación similar a la que puede presentarse en una institución educativa real, donde los datos pueden contener duplicados, campos vacíos, valores fuera de rango o información inconsistente.

Durante el proceso ETL se aplicaron técnicas de limpieza y transformación de datos utilizando Power Query. Esto permitió corregir valores inválidos, eliminar registros duplicados, completar datos faltantes y crear una nueva columna de clasificación llamada nivel_academico. Con ello, los datos pasaron de estar desordenados y con errores a convertirse en un conjunto limpio y preparado para su análisis.

También se diseñó un modelo de Data Warehouse utilizando un esquema estrella. Este modelo permitió organizar la información en una tabla de hechos, hechos_rendimiento, y varias dimensiones, como alumno, carrera, tiempo, materia y profesor. Esta estructura facilita realizar consultas de análisis de manera más clara, ya que permite estudiar el rendimiento académico desde diferentes perspectivas.

La carga de datos en MySQL permitió implementar físicamente el Data Warehouse y comprobar que la información limpia podía ser almacenada y consultada correctamente. A través de las consultas SQL fue posible obtener resultados como carreras con mayor cantidad de alumnos en riesgo, promedio general por carrera, relación entre asistencia y promedio, y materias con menor rendimiento.

En conclusión, este proyecto permitió aplicar de manera práctica los conceptos de extracción, transformación y carga de datos, además de comprender cómo un Data Warehouse puede apoyar la toma de decisiones académicas. Gracias a este tipo de soluciones, una universidad puede identificar alumnos en

riesgo, detectar áreas con bajo rendimiento y diseñar estrategias de apoyo basadas en datos reales y organizados.

[↑ Regresar al índice](#)